

Contents

阈值 S	1
1. 算法实现（第 a 部分）	1
2. 输入数据（第 b 部分）	2
3. 理论分析	2
4. 比较次数随 n 的变化（第 c(i) 部分）	4
5. 比较次数随 S 的变化（第 c(ii) 部分）	6
6. 如何选择 S （第 c(iii) 部分）	7
7. 时间究竟花在哪里	8
8. 与原始归并排序的对比（第 d 部分）	10
9. 结论的适用边界	10
10. 结论	11
附录——如何复现	11

阈值 S

SC2001 Project 1 ——归并排序与插入排序的融合

在小子数组上切换到插入排序的归并排序，比纯归并排序更快。但按照本作业要求绘制的每一项指标衡量，它又都更差。本报告调和这两个事实。

测量环境：Python 3.13, Apple Silicon, macOS 24.6, n 最大至 10^7 。所有图表均由 results/ 目录下的 CSV 生成。

关键比较次数	对任何 S ，混合算法所需的比较次数都不会少于纯归并排序。已精确证明。
CPU 时间	在 $n = 10^7$ 且取最优 S 时快 11.9%：16.56 秒对 18.81 秒。
最优叶子大小	7-10，在跨越四个数量级的 n 上保持恒定。

1. 算法实现（第 a 部分）

混合算法就是在递归开头多加一行判断的归并排序。当子数组长度降到 S 或更短时，它交给插入排序，而不再继续拆分。这个判断在每个分支上独立执行，因此树的不同部分会在各自长度所决定的深度上触底。

三个排序共用一套计数口径，每个都返回排好序的列表以及执行的关键比较次数：

函数	作用
hybrid(arr, S)	混合算法。 $S = 1$ 时退化为纯归并排序，因为单元素子数组交给插入排序不产生任何代价。
mergesort(arr)	教科书版归并排序，一直递归到单个元素。第 (d) 部分的对照基线。
insertsort(arr)	插入排序，键归位后立即提前退出，因此具有自适应性，而非恒定处于最坏情况。

什么算一次关键比较

关键比较是指两个数组元素之间的一次比较：插入排序中的 $a[j] > \text{key}$ ，以及归并步骤中的 $a[i] \leq b[j]$ 。诸如 $j \geq 0$ 和 $i < \text{len}(a)$ 这类循环边界判断不计入， $\text{len}(arr) \leq S$ 这个尺寸判断同样不计入，因为它们都没有检视任何键值。这一点很重要——尺寸判断在每次递归调用时触发一次，若计入，会给小 S 的计数额外叠加一个正比于 n 的项。

正确性验证

模块每次执行时都会运行三项检查：

- 对 n 从 0 到 4096，三种排序的结果都与 `sorted()` 一致；混合算法在 $S \in \{1, 2, 5, 16, 64, n + 5\}$ 的每个取值下同样一致。
- **hybrid(arr, 1)** 报告的比较次数与 **mergesort(arr)** 完全相同——在 $n = 5000$ 时是 55,178 对 55,178。逐位相等说明切换逻辑既没有重复计数，也没有漏计任何一次比较。
- 插入排序具备自适应性：在长度 1000 的有序数组上是 999 次比较 ($n - 1$ 的最好情况)，在逆序数组上是 499,500 次 ($n(n - 1)/2$ 的最坏情况)。

测量陷阱。携带计数器会使运行时间增加约 15%，因为递归的每一层都要打包和拆包一个元组。因此本报告中所有 CPU 时间均来自另一套不计数的孪生实现 (`hybrid_nc`、`mergesort_nc`、`insertsort_nc`)，它们除此之外逐行相同。比较次数与计时数据从不取自同一次运行。

2. 输入数据 (第 b 部分)

数组元素为 $[1, x]$ 上的均匀随机整数，取 $x = 10^7$ 。十三个规模以 1-2-5 递进覆盖要求的范围——1000、2000、5000、10,000、.....、10,000,000——使它们在第 (c) 部分所需的对数坐标轴上均匀分布。

数组采用由种子重新生成而非存储的方式。一千万元素的数组在内存中约占 400 MB；作为种子它只占一个整数，且运行结果完全可复现。生成时优先使用 `numpy` (约快 3 倍)，无 `numpy` 时回退到标准库。

采样说明。在种子固定的情况下，较小的数组是较大数组的前缀。这是刻意为之：它在第 (c)(i) 部分中隔离出 n 的影响，而不掺入不同规模之间的采样噪声。若要在多次重复上取平均，必须改变种子，而不能只是重复运行。

3. 理论分析

以下全部为均匀随机排列下的平均情况分析，因为生成的数据正是如此。当最坏情况在性质上有所不同时，会另行说明。

3.1 插入排序

考虑把 $a[i]$ 插入长度为 i 的有序前缀。设 t 为前缀中大于该键的元素个数。在随机排列下，该键等可能地落入 $i + 1$ 个间隙中的任意一个，因此 t 在 $\{0, \dots, i\}$ 上均匀分布。若 $t < i$ ，循环执行 t 次成功比较外加一次失败比较，共 $t + 1$ 次。若 $t = i$ ，该键小于所有元素，循环在仅 i 次比较后越过左端结束，不产生失败判断。因此

$$\mathbb{E}[C_i] = \frac{1}{i+1} \left(\sum_{t=0}^{i-1} (t+1) + i \right) = \frac{1}{i+1} \left(\frac{i(i+1)}{2} + i \right) = \frac{i}{2} + \frac{i}{i+1}$$

对 $i = 1, \dots, m-1$ 求和并合并调和级数尾项, 得到闭式:

$$I(m) = \frac{m(m-1)}{4} + m - H_m$$

其中 $H_m = \sum_{k=1}^m 1/k$ 为第 m 个调和数。最坏情况为 $m(m-1)/2$, 最好情况为 $m-1$ 。

注意平均值并非简单地等于最坏情况的一半。 $m - H_m$ 这一项是那些落到最左端的键所付出的额外代价, 在 $m = 8$ 时它贡献了 19.28 中的 5.28。

3.2 归并步骤

归并两个长度分别为 a 和 b 的有序段, 代价为 $a+b$ 减去某一段耗尽后被整体搬运的尾块长度。记该尾块长度为 T , 则

$$\Pr[T \geq k(\text{来自段 } A)] = \frac{\binom{a+b-k}{b}}{\binom{a+b}{b}}$$

对 k 求和, 利用曲棍球棒恒等式 $\sum_{j=b}^{a+b-1} \binom{j}{b} = \binom{a+b}{b+1}$ 裂项相消, 得 $\mathbb{E}[T] = \frac{a}{b+1} + \frac{b}{a+1}$ 。因此

$$M(a, b) = a + b - \frac{a}{b+1} - \frac{b}{a+1}$$

最坏情况为 $a+b-1$ 。归并排序的平均代价服从如下显然的递推, 其中 $MS(1) = 0$:

$$MS(m) = MS(\lfloor \frac{m}{2} \rfloor) + MS(\lceil \frac{m}{2} \rceil) + M(\lfloor \frac{m}{2} \rfloor, \lceil \frac{m}{2} \rceil)$$

3.3 单个子数组上的抉择

这是问题的核心。在长度为 m 的子数组上, 算法要在支付 $I(m)$ 和支付 $MS(m)$ 之间做选择。用精确有理数运算计算两者:

m	$I(m)$	$MS(m)$	$I(m) - MS(m)$	更省
2	1	1	0	平局
3	2.667	2.667	0	平局
4	4.917	4.667	+1/4	归并
5	7.717	7.167	+11/20	归并
6	11.050	9.833	+73/60	归并
7	14.907	12.733	+913/420	归并
8	19.282	15.733	+2981/840	归并
16	72.619	45.689	+26.93	归并
32	275.942	121.495	+154.45	归并
64	1067.256	305.051	+762.21	归并

表 1. 单个子数组上的平均关键比较次数, 精确值。

对 $m = 2$ 和 $m = 3$ 有 $I(m) = MS(m)$ 精确成立, 对每个 $m \geq 4$ 有 $I(m) > MS(m)$ 。这些差值是精确的有理数, 不是四舍五入的结果。因此在关键比较次数这一指标上, 混合算法永远无法胜过纯归并排序, 至多只能在叶子大小不超过 3 时与之打平。

一次独立的蒙特卡洛实验 (每种规模 200,000 个随机数组) 在 0.2% 以内复现了表 1 的每一个数值, 这正是该试验次数下的预期采样误差。

3.4 作为整体的混合算法

取 n 和 S 均为 2 的幂，则全部 n/S 个叶子的长度恰好都是 S 。最坏情况下，叶子部分的代价为 $\frac{n}{S} \cdot \frac{S(S-1)}{2}$ ，其上方 $\log_2(n/S)$ 层归并的代价为 $n \log_2(n/S) - n/S + 1$ ：

$$C(n, S) = \frac{n(S-1)}{2} + n \log_2 \frac{n}{S} - \frac{n}{S} + 1$$

令 $S = 1$ 即还原为熟悉的 $n \log_2 n - n + 1$ 。两式相减得到设置阈值的代价，它关于 n 是线性的，系数仅取决于 S ：

$$\Delta(S) = n \left[\frac{S-1}{2} - \log_2 S + 1 - \frac{1}{S} \right]$$

Δ 在 $S = 1$ 和 $S = 2$ 时恰好为零，随后在 $S = 4$ 时为 $+0.25n$ ， $S = 8$ 时为 $+1.375n$ ， $S = 16$ 时为 $+4.44n$ ， $S = 32$ 时为 $+11.47n$ 。最坏情况的图景与表 1 的平均情况一致：任何高于最小值的阈值都不会降低比较次数。

3.5 渐近性

对任何固定的 S ，插入排序项为 $\Theta(nS) = \Theta(n)$ ，被 $n \log n$ 项所主导：

$$C(n, S) = n \log_2 n + n \left[\frac{S-1}{2} - \log_2 S \right] - \frac{n}{S} + 1 = \Theta(n \log n)$$

阈值改变的是常数因子，绝不改变复杂度类别。只有当 S 被允许随 n 增长时这一点才会失效：在 $S = \Theta(n)$ 时整个数组都交给插入排序，代价变为 $\Theta(n^2)$ 。

4. 比较次数随 n 的变化（第 c(i) 部分）

固定 $S = 8$ ，两种排序在全部十三个规模上运行。在对数-对数坐标上直接绘制 $C(n)$ 对 n 的曲线是一种糟糕的检验，因为几乎任何超线性曲线在那里看起来都是直的。绘制 $C(n)/n$ 对 $\log n$ 的曲线要锐利得多：理论断言该量是线性的，因此任何偏离直线的形状都构成对模型的证伪。




图 1. 上：每元素比较次数随 n 的变化。标记点为实测值，曲线为第 3 节平均情况模型的精确取值——两者在四个数量级上重合，验证了 $\Theta(n \log n)$ 及其前面的常数。下：CPU 时间优势，随 n 增大从 $1.36\times$ 衰减到 $1.08\times$ 。

n	混合算法比较次数	归并比较次数	超出	混合 CPU	归并 CPU	加速比
1,000	9,088	8,717	+4.26%	0.00053 s	0.00072 s	1.36×
2,000	20,217	19,422	+4.09%	0.00121 s	0.00161 s	1.33×
5,000	55,766	55,237	+0.96%	0.00373 s	0.00464 s	1.24×
10,000	121,468	120,431	+0.86%	0.00825 s	0.01005 s	1.22×
20,000	263,085	260,942	+0.82%	0.0189 s	0.0232 s	1.23×
50,000	729,394	718,417	+1.53%	0.0501 s	0.0595 s	1.19×
100,000	1,558,492	1,536,560	+1.43%	0.1071 s	0.1272 s	1.19×
200,000	3,315,992	3,272,943	+1.32%	0.2304 s	0.2706 s	1.17×
500,000	9,036,918	8,837,196	+2.26%	0.6255 s	0.7263 s	1.16×
1,000,000	19,073,414	18,674,561	+2.14%	1.3307 s	1.5472 s	1.16×
2,000,000	40,148,187	39,349,331	+2.03%	2.8853 s	3.3060 s	1.15×
5,000,000	105,556,634	105,052,333	+0.48%	7.9996 s	8.9849 s	1.12×
10,000,000	221,112,527	220,105,208	+0.46%	17.576 s	18.994 s	1.08×

表 2. 第 (c)(i) 部分, $S = 8$ 。比较次数为精确值; CPU 时间在小规模上取 7 次运行的中位数, 到一千万时降为 2 次。

“超出”这一列并非平滑下降, 其原因贯穿整个第 (c) 部分。在 $S = 8$ 时, 叶子的长度并非全是 8——它们是 $\lceil n/2^k \rceil$ 落到 8 或以下时的那个值。在 $n = 10^6$ 时是 7-8, 但在 $n = 10^7$ 时是 4-5, 更接近纯归并排序, 这正是那里超出仅为 0.46% 的原因。同一个 S 在不同的 n 上含义并不相同。

图 1 中的吻合回答了“与你的理论分析作对比”这一要求: 在每个规模上, 第 3 节的模型对实测计数的预测误差都优于 0.1%, 且每元素比较次数按推导所要求的斜率跟随 $\log_2 n$ 。

5. 比较次数随 S 的变化 (第 c(ii) 部分)

在 $n = 1,000,000$ 上取二十二个 S 值, 每个计时五次。给定数组和 S 后比较次数是确定的, 因此只测一次; 只有计时需要重复。

Hybrid merge sort, $n = 1,000,000$: the two metrics disagree




图 2. 两项指标指向相反的方向。关键比较次数 (上) 单调上升, 从未低于纯归并排序的水平线。CPU 时间 (下) 下降至 $S = 8-24$ 附近的一段平坦最小值, 之后才回升。若把两者画成双 y 轴, 会诱使读者去解读一个纯粹由两个刻度对齐位置造成的交叉点。

S 是被量化的

比较次数呈平台状分布，且平台边界与对半阶梯 $\lceil n/2^k \rceil$ 精确对齐。同一平台内的每个 S 产生完全相同的执行过程——计数是逐位相等，而不仅仅是接近。 $S = 8, 10, 12, 14$ 并非四个相近的选择，而是同一个算法被测量了四次，它们计时上约 1% 的离散度只是测量噪声，别无其他。

S	叶子大小	关键比较次数	对归并之比	CPU 中位数	加速比
1	1	18,674,561	1.00×	1.7526 s	0.95×
2	1-2	18,674,561	1.00×	1.5903 s	1.05×
3	2-3	18,674,513	1.00×	1.5717 s	1.06×
4	3-4	18,727,864	1.00×	1.4766 s	1.13×
5	3-4	18,727,864	1.00×	1.4769 s	1.13×
6	3-4	18,727,864	1.00×	1.4710 s	1.14×
8	7-8	19,073,414	1.02×	1.4188 s	1.18×
10	7-8	19,073,414	1.02×	1.4128 s	1.18×
12	7-8	19,073,414	1.02×	1.4262 s	1.17×
14	7-8	19,073,414	1.02×	1.4252 s	1.17×
16	15-16	20,222,242	1.08×	1.4150 s	1.18×
20	15-16	20,222,242	1.08×	1.4370 s	1.16×
24	15-16	20,222,242	1.08×	1.4138 s	1.18×
32	30-31	23,186,948	1.24×	1.4829 s	1.13×
40	30-31	23,186,948	1.24×	1.5108 s	1.11×
48	30-31	23,186,948	1.24×	1.5328 s	1.09×
64	61-62	29,880,484	1.60×	1.7342 s	0.96×
96	61-62	29,880,484	1.60×	1.7451 s	0.96×
128	122-123	44,185,373	2.37×	2.3394 s	0.71×
192	122-123	44,185,373	2.37×	2.3558 s	0.71×
256	244-245	73,735,430	3.95×	3.5532 s	0.47×
512	488-489	133,829,093	7.17×	6.6962 s	0.25×

表 3. 第 (c)(ii) 部分， $n = 1,000,000$ 。叶子大小一列给出插入排序实际接收到的子数组长度，它解释了每一个平台。加粗行为处于最快值 1% 以内者。纯归并排序：18,674,561 次比较，1.6713 秒。

与理论对照：第 3.4 节的平均情况模型，在实际（不均匀的）子数组长度而非 2 的幂理想化情形下取值，对这二十二个计数的预测误差全部在 0.07% 以内。最大误差出现在 $S = 64$ (+0.064%)，那里叶子长度最不均匀。

比较次数曲线的最小值出现在 $S = 3$ ，此处它以 1870 万次中的 48 次之差低于纯归并排序——0.0003% 的改进，这正是表 1 所预测的平局在实测中的体现。若把第 (c)(ii) 部分严格理解为对关键比较次数的优化，答案就是 $S = 3$ ，而混合算法毫无意义。CPU 时间曲线才是该算法证明自身价值的地方，第 7 节解释两者为何背离。

6. 如何选择 S （第 c(iii) 部分）

在跨越四个数量级的四个规模上重复扫描，每个 S 都与纯归并排序在同一数组上对比计时。




图 3. 相对纯归并排序的加速比随 S 的变化，每种输入规模一条曲线，圆环标出各曲线的最优点。尽管规模相差 1000 倍，最优点却彼此重叠。 $n = 10^7$ 的曲线使用较粗的网格，因为每个点约需 35 秒。

n	最优 S	叶子大小	混合 CPU	归并 CPU	加速比
10,000	12	9-10	0.0081 s	0.0104 s	1.29×
100,000	12	6, 7, 12	0.1063 s	0.1263 s	1.19×
1,000,000	12	7-8	1.3484 s	1.5267 s	1.13×
10,000,000	16	9-10	16.5645 s	18.8082 s	1.14×

表 4. 各规模下最快的 S 及其对应的叶子大小。最优 S 在移动，最优叶子大小则不然。

在所有测试规模上，最优叶子大小都是 7-10，尽管产生它的 S 从 12 移到了 16。这正是理论所预测的：长度为 m 的子数组上的抉择，比较的是 $I(m)$ 与 $MS(m)$ 加上每次调用的开销，而这两个量都不涉及 n 。该决策对子数组而言是局部的，因此其答案不可能取决于整个数组有多大。

由此得出实用建议：报告最优叶子大小，而不是最优 S 。引用“ $S = 12$ ”是所测 n 的产物——在 $n = 10^7$ 上同一个 12 给出的叶子是 4-5，会损失可得加速的 5%。而引用“在叶子大小 ≈ 8 处切换”则是可迁移的。

关于精度还有一点补充：在 $n = 10^6$ 上， $S = 8, 10, 12, 14$ 是同一个算法，而 $S = 16, 20, 24$ 与它们在五次运行的中位时间上仅差 0.07%。再多的重复也无法区分这两个平台。诚实的答案是一个区间，而非一个点。

7. 时间究竟花在哪里

第 3 节和第 5 节留下了一个表面上的矛盾：混合算法做了更多关键比较，却更早结束。答案在于关键比较并不是归并排序把时间花掉的地方。

7.1 两种排序实际执行了什么

操作	归并排序	插入排序
递归调用	15	1
.....其中排序单个元素的	8	—
归并步骤	7	0
列表切片	21	0
新分配的列表	15	1
append / extend	17 / 7	0
关键比较	~16	~19

表 5. 对一个 8 元素数组排序一次所执行的操作。

归并排序十五次调用中有八次是在排序单元素数组。它们检查一个长度、复制一个单元素列表、然后返回。它们执行零次比较、移动零个元素；它们存在的唯一理由是递归需要一个基准情形。

7.2 时间归因

把归并排序逐层剥离即可分离出每一项代价。以下为对 8 元素数组排序一次的微秒数，取 4000 个数组上 7 轮中的最优值：

层次	μs / 次排序	增量
仅递归 + 21 次切片 + 8 次叶子拷贝	1.046	—
.....加上分配 7 个结果列表	1.340	+0.294
.....加上归并本身——完整归并排序	2.810	+1.470
完整的插入排序	0.980	
在 $m = 8$ 处切换所节省的	1.830	

表 6. 归并排序代价的分解。脚手架占了总量的一半。

这 1.830 μs 干净地分成两部分：

- **1.340 μs** ——整棵递归树消失了。十五次调用塌缩为一次；21 次切片、8 次叶子拷贝和 7 个结果列表塌缩为一次 `list(arr)`。这占归并排序总代价的 47.7%，全部花在把数组拆开再拼回去上。
- **0.490 μs** ——归并的内层循环单位代价更高。归并步骤本身耗时 1.470 μs ，尽管少做了三次比较，却是整个插入排序代价的 1.50 倍。放置一个元素需要 `new.append(x)`，即一次属性查找加一次方法调用；而插入排序做的是 `arr[j+1] = arr[j]`，一条存储指令。归并循环还在每次迭代中重新求值 `len(a)` 和 `len(b)`。

7.3 这笔交易为何如此悬殊

两类代价在递归树上的分布方式不同，这种不对称就是全部答案。

树的每一层总共归并 n 个元素，因此每一层约耗费 n 次比较。在 $\log_2 n$ 层上，比较工作量是均匀铺开的：在 $n = 10^6$ 时，约 20 层中的每一层各占总量的约 5%。

节点数则不是均匀分布的。 n 个元素的树有 n 个叶子和 $n - 1$ 个内部节点，因此仅最底一层就占了全部节点的一半：

$$\frac{\text{最底 } j \text{ 层的节点数}}{\text{总节点数}} = \frac{n + \frac{n}{2} + \cdots + \frac{n}{2^{j-1}}}{2n - 1} \approx 1 - 2^{-j}$$

于是最底三层占了其中的 87.5%。

在叶子大小 8 处切断即移除最底三层。这舍弃了全部函数调用、切片和内存分配中的 87.5%，换来的代价是三层的比较工作量——插入排序随后以略差的效率重做这部分，多花约 2% 的比较。在 $n = 10^6$ 上实测：比较次数 +2.1%，CPU 时间 -15%。

7.4 两个交叉点

由于两项指标衡量的是不同的东西，它们在不同的子数组长度上交叉。比较次数取每种规模 200,000 个随机数组的实测值，计时取五次中的最优值：

m	比较次数更省者	CPU 时间更快者	归并/插入 时间比
2	平局	插入	2.32×
4	归并	插入	2.99×
8	归并	插入	2.77×
16	归并	插入	2.30×
32	归并	插入	1.56×
64	归并	归并	0.87×

表 7. 在小子数组上按各指标衡量谁胜出。比较次数的交叉点在 $m \approx 3$ ；CPU 时间的交叉点在 $m \approx 48$ 。

作业本身的表述已经预示了这一点：它用“大量递归调用的开销”来论证混合算法的必要性，而不是用比较次数。表 6 就是这句话的量化版本。

8. 与原始归并排序的对比（第 d 部分）

在 $n = 10,000,000$ 上，采用第 (c)(iii) 部分得出的最优 $S = 16$ ，对照第 1 节的教科书版归并排序。两种排序均已验证产生相同输出。

	关键比较次数	对归并	CPU 时间	对归并
混合算法, $S = 16$	226,423,622	+2.87%	16.564 s	-11.9%
混合算法, $S = 8$	221,112,527	+0.46%	17.472 s	-7.1%
纯归并排序	220,105,208	—	18.808 s	—

表 8. 一千万整数上的正面对决。两个算法排序的是同一个数组。

这个结果就是本报告论点的一行浓缩。混合算法多做了 630 万次关键比较，却仍早 2.24 秒完成。在第 (c)(i) 和 (c)(ii) 部分要求绘制的指标上它输了；在第 (d) 部分要求测量的指标上它赢了 11.9%。

$S = 8$ 那一行从另一个角度展示了量化效应：它多付出的比较次数少得多 (+0.46%)，恰恰因为它的叶子只有 4-5 个元素，而它也相应地更慢，只捕获了 7.1% 而非 11.9% 的加速。更少的比较、更低的速度——在 S 的整个有用范围上，两项指标是反相关的。

运行间方差。一千万规模的纯归并排序在第 (c)(iii) 部分的运行中测得 18.808 秒，在第 (d) 部分的独立运行中测得 18.298 秒，两次会话间相差 2.7%。在此规模下，低于约 3% 的差异不应被视为真实。11.9% 的差距远在该带宽之外；而 $S = 12$ 与 $S = 16$ 之间的差距则不是。

9. 结论的适用边界

最优值是实现常数，而非算法性质。表 6 把归并排序 47.7% 的代价归因于切片与内存分配。基于索引的原地归并排序，使用一个预分配缓冲区并传递 (lo, hi) 而非子列表，可消除其中的大部分，只留下函数调用本身。它的交叉点会落在更小的 m 上，最优叶子大小会低于 8。“叶子大小 ≈ 8 ”这个数字是本实现和本语言特有的；可迁移的是推理过程，而非这个数字。这一点未经实测，仅作为预期而非结论陈述。

仅涵盖均匀随机数据。插入排序的提前退出使其具有很强的自适应性——有序输入上 999 次比较，逆序输入上 499,500 次。在部分有序的数据上，最优 S 会更大，可能大得多。本报告未对该情形做任何测量。

嵌套数据集。在固定种子下，每个规模都是下一个规模的前缀。这通过消除规模间的采样噪声锐化了第 (c)(i) 部分，但这十三个点并非独立抽样，因此跨规模的置信区间会偏乐观。

大规模处计时重复次数偏少。一千万元素的运行重复了 2 次，五百万重复 3 次。结合 2.7% 的会话间方差，大 n 处的加速比带有约 $\pm 3\%$ 的不确定度。比较次数则不带任何不确定度——它们是精确的。

重复键。取值来自 $[1, 10^7]$ 而 $n = 10^7$ 时，约 37% 的条目是重复值。归并使用 $a[i] \leq b[j]$ ，因此相等时取左段，使排序稳定并把相等情形的代价固定为一次比较。换一种相等处理约定会使计数略有变化。

10. 结论

混合算法值得使用，但理由并非第 (c)(i) 和 (c)(ii) 部分那个指标所暗示的那个。

1. 在关键比较次数上混合算法从未胜出。精确地说： $m \leq 3$ 时 $I(m) = MS(m)$ ，之后 $I(m) > MS(m)$ ，因此比较次数最优的阈值是 $S = 3$ ，而它在 1870 万次中只省下 48 次。
2. 在 CPU 时间上它在一千万规模下胜出 **11.9%**。收益来自删除递归树最底的三层，那里集中了 87.5% 的调用、切片和内存分配，却只承担约 15% 的比较工作量。
3. 最优叶子大小为 **7-10** 且不依赖于 n ，因为子数组上的抉择只涉及该子数组自身的长度。应当报告叶子大小；实现它的 S 被 $\lceil n/2^k \rceil$ 量化，会随输入规模移动。
4. 对任何固定的 S ，混合算法仍是 $\Theta(n \log n)$ 。阈值买到的是常数因子，绝不是复杂度类别。

更广的方法论意义在于：两项指标在 S 的整个有用范围上是反相关的，因此一份优化关键比较次数的报告和一份优化运行时间的报告，会从同一批数据得出相反的结论。哪个正确取决于这个计数当初是什么东西的代理指标——而在纯 Python 中，在一个 8 元素子数组上，它是大约一半工作量的代理。

附录——如何复现

文件	内容
hybrid.py	三个带比较计数的排序，以及用于计时的不计数孪生实现。运行它会执行验证套件。
datagen.py	基于种子的数组生成与规模阶梯。
experiments.py	第 (c)(i)、(c)(iii) 和 (d) 部分。约 15 分钟；写出三个 CSV。
bench.py	第 (c)(ii) 部分： S 扫描，以及平台列背后的 leafsizes 辅助函数。
overhead.py	表 5 和表 6。必须在空闲机器上运行。
plots.py	图 1-3，由 CSV 绘制。

所有数字均由上述脚本生成并存放于 results/*.csv。比较次数是精确的，可由种子复现；CPU 时间在一台空闲的 Apple Silicon 机器上、Python 3.13 环境下测得，在其他硬件上会有差异。

图中的坐标轴标签保留英文，与代码和 CSV 的列名保持一致。